

شرح پروژه

هدف از پروژه web scraping صفحه فروش شگفت انگیز دیجیکالا، سرعت بخشیدن به روند خرید و فروش و کسب آسان تر اطلاعات هست. در این پروژه از زبان برنامه نویسی پایتون و کپیج های pandas, BeautifulSoup4, urllib بهره گرفته شده است. ابتدا به بررسی صفحه اصلی پرداخته و سپس کد توضیح داده میشود.

[illegible]

<https://www.digikala.com/incredible-offers/>

در این صفحه قسمت های متعددی وجود دارند که بخش بالا، قسمت مد نظر ما هست. که همه کالا ها با تخفیف مذکور لیست شده اند. در سورس صفحه در این قسمت اطلاعات زیر موجود هستند:

[illegible]

که اگر مرتب شوند دیده میشود که داده ها در تگ های متناسب قسمت بندی شده اند.

نام ها در تگ `div class={c-product-box__title js-ab-not-app-incredible-product}`

`div class={c-price value-wrapper js-product-card-price}` قیمت ها در تگ

تخفیف ها در تگ `div class={c-price discount-oval}`

با استخراج داده های این تگ ها داده مورد نیاز خود را بدست میآوریم.

در توضیح کد

ابتدا کتابخانه های مورد نیاز را وارد میکنیم

```
from bs4 import BeautifulSoup
from urllib.request import Request, urlopen
import pandas as pd
```

سپس آدرس سایت و برای داده های خود 3 لیست در نظر میگیریم. همچنین برای تعداد صفحات مورد بررسی و تعداد کالا ها متغیر هایی در نظر میگیریم

```
# https://www.digikala.com/incredible-offers/
originalUrl = "https://www.digikala.com"
urlLink = originalUrl + "/incredible-offers/"

names = []
offs = []
prices = []
noPages = 3
itemCount = 0
```

وارد حلقه برای تعداد صفحات میشویم، برای هر صفحه ابتدا لینک کامل را ساخته، سپس به آن سایت و سرور درخواست فرستاده و جواب را میخوانیم و به کمک کتابخانه bs4 اطلاعات صفحه را پردازش میکنیم

```
for i in range(1, noPages):

    url = urlLink + '?pageno=' + str(i)

    r = Request(url, headers={'User-Agent': 'Mozilla/5.0'})
    webpage = urlopen(r).read()
    soup = BeautifulSoup(webpage, 'html.parser')
```

بعد از دریافت page source، مطابق تگ های توضیح داده شده در قسمت قبل، بخش کالا های خود را جدا کرده و در آن بخش ها داده های مورد نیاز خود را جدا میکنیم، همچنین به ازای هر کالا مقدار متغیر شمارش کالا یکی اضافه میشود

```
for row in soup.findAll('div', attrs={'class': 'c-product-list__item js-product-list-content'}):
    itemCount += 1
    rName = row.find('div', attrs={'class': 'c-product-box__title js-ab-not-app-incredible-product'})
    rPrice = row.find('div', attrs={'class': 'c-price__value-wrapper js-product-card-price'})
    rOff = row.find('div', attrs={'class': 'c-price__discount-oval'})
```

داده اسم کالا در سورس صفحه شامل فاصله های خالی و اضافی هست. این مشکل در تابع `replaceMultiple` رفع شده است، بدین صورت که یک `dict` برای تعویض فاصله های اضافی با فضای خالی در نظر گرفته شده، که در این تابع به ترتیب این تعویض ها انجام میشوند

```
def replaceMultiple(txt, dic):  
    for i, j in dic.items():  
        txt = txt.replace(i, j)  
    return txt
```

همچنین در صورت اتمام تخفیف، داده قیمت مقدار `None` به خود میگیرد که برای رفع آن مشکل از تابع `checkActive` استفاده شده. در این تابع شرطی بررسی میشود که اگر کالا موجود بود، قیمت آن و اگر نبود خروجی `None` داده شوند

```
def checkActive(ro):  
    if ro != None:  
        return ro.text  
    else:  
        return None
```

برای راحتی نوشتار، این دو عملیات در تابع `result` باهم ادغام شده اند

```
def result(inp):  
    global replaceDict  
    out1 = checkActive(inp)  
    if out1:  
        return replaceMultiple(out1, replaceDict)  
    else:  
        return 'not available'
```

داده تخفیف نیز در `div` مخصوص خود، در قسمت `span` قرار دارد. با توجه به مشکلات استخراج داده `span`، برای بدست آوردن مقدار تخفیف، از عملیات روی متن استفاده شده است، بدین صورت که متن بین تگ های `span` و `/span` خارج میشود. این عملیات در تابع `extractText` پیاده سازی شده است

```
def extractText(txt, sth):  
    tagStart = '<'+sth+'>'  
    tagEnd = '</'+sth+'>'  
    res1 = txt.find(tagStart)  
    res2 = txt.find(tagEnd)  
    if (res1 != -1):  
        theIt = txt[res1+len(tagStart):res2]  
        return theIt  
    else:  
        return None
```

پس از آماده سازی اولیه داده های نام و قیمت و تخفیف، آنها را در لیست های مربوطه اضافه میکنیم

```
name = result(rName)
price = result(rPrice)
off = extractText(str(rOff), 'span')
names.append(name)
prices.append(price)
offs.append(off)
```

پس از بررسی همه سایت ها(که در این مورد صفحات 1 و 2 موجود بودند) داده ها را در یک dict ذخیره میکنیم و سپس آن را به فرمت DataFrame از پکیج pandas در میآوریم. هدف از این کار راحتی و امکانات کار با داده در pandas هست

```
dic = {'Name':names, 'Price':prices, 'Off':offs}
df = pd.DataFrame(dic)
```

سپس میتوانیم داده ها را به فرمت CSV تبدیل کنیم تا در سایر برنامه ها نیز قابلیت خواندن داشته باشد، لازم به ذکر است چون داده ها به زبان فارسی هستند، از utf-8 encoding استفاده میکنیم

```
df.to_csv('file1.csv', index=False, encoding='utf-8')
```

- داده هایی که اتمام موجودی باشند، قیمت و تخفیف نخواهند داشت
- داده هایی که تخفیف آنها به پایان رسیده باشد، در ستون تخفیف مقداری ندارند.

	Name	Price	Off
0	redmi 9T M2010J19SG گوشی موبایل شیائومی مدل ...	تومان ۳,۹۰۹,۰۰۰	۵٪
1	ژل آبرسان کامان مدل آلوفه ورا حجم 400 میلی لیتر	تومان ۳۳,۹۰۰	۲۶٪
2	بسته ۳ عددی Mini بالم لب مرو مدل	تومان ۱۴,۰۰۰	۳۳٪
3	A10E-1 مبدل برق هادرون مدل	تومان ۳۶,۹۰۰	۲۰٪
4	EK33118 مداد شمعی 12 رنگ اریک کراوزه مدل	تومان ۱۲,۹۰۰	۴۸٪
...
61	Ma-1 کیف اداری چرم ما مدل	تومان ۶۳۰,۰۰۰	۳۶٪
62	BRIX Blocks ساختمانی مدل 2007-1	تومان ۷۱,۵۰۰	۴۰٪
63	کیف رودوشی گوگانا کد 300301	not available	None
64	SRM90 جاتماز ترمه طرح شاه عباسی کد	not available	None
65	C101 کفش روزمره زنانه شیفر مدل 5330	not available	None

66 rows × 3 columns

همچنین برای راحتی بیشتر، در قسمت اضافی پروژه، داده های برست آمده در یک صفحه وب نیز ذخیره میشوند

df.to_html('file2.html')

	Name	Price	Off
0	ظرفیت 128 گیگابایت و رم 4 گیگابایت redmi 9T M2010J19SG گوشی موبایل شیائومی مدل	تومان ۳,۹۰۹,۰۰۰	۵٪
1	ژل آبرسان کامان مدل آلوئه ورا حجم 400 میلی لیتر	تومان ۳۳,۹۰۰	۲۶٪
2	بسته ۳ عددی Mini بالم لب مرو مدل	تومان ۱۴,۰۰۰	۳۳٪
3	A10E-1 مبدل برق هادرون مدل	تومان ۳۶,۹۰۰	۲۰٪
4	EK33118 مداد شمعی 12 رنگ اریک کراوزه مدل	تومان ۱۲,۹۰۰	۴۸٪
5	بسته 500 عددی A+ فولیو پرایم مدل A4 کاغذ	تومان ۶۶,۵۰۰	۱۹٪
6	FCLT3337 ساک لوازم کودک و نوزاد فوروارد کد	تومان ۱۶۹,۰۰۰	۷۴٪
7	کتاب اثر مرکب اثر دارن هاردی انتشارات باران خرد	تومان ۱۹,۶۰۰	۸۰٪
8	حجم 150 میلی لیتر Bvlgari اسپری ضد تعریق مردانه پرستیز مدل	تومان ۱۲,۹۰۰	۱۹٪
9	تی شرت زنانه کد 120	تومان ۶۰,۰۰۰	None
10	حجم 85 میلی لیتر Warrior ادو پرفیوم مردانه اسکاتره مدل	تومان ۱۵۵,۹۵۰	None
11	کتاب پنج قدم فاصله اثر ریچل لیبینکات نشر میلکان	تومان ۳۶,۸۰۰	۳۲٪
12	مجموعه 6 عددی A211 جوراب مردانه مدل نویدکد	تومان ۷۴,۵۰۰	۵۷٪
13	FCLT3060 کیف ابزار فوروارد مدل	تومان ۴۹,۰۰۰	۵۹٪
14	ظرفیت 10000 میلی آمپر ساعت PB01 شارژر همراه رانیک پرایم مدل	تومان ۱۹۹,۰۰۰	۴۵٪
15	FCLT402-2 کوله پشتی 65 لیتری فوروارد مدل	تومان ۳۲۹,۹۰۰	۶۱٪
16	روان نویس طرح یونیکورن کد 9911	تومان ۲۹,۰۰۰	۲۸٪
17	سرویس خواب ژینورا مدل هانا بکنفره 2 تکه	تومان ۴۰۰,۰۰۰	None